EVALUACIÓN MÓDULO 5

Proyecto: “Análisis estadístico sobre hábitos saludables en jóvenes universitarios”

Reinaldo Elgueta Ábalos.
Curso Fundamento de Ciencia de Datos
SENCE / ALKEMY
28 de febrero 2026

Introducción

En el entorno de las instituciones públicas de educación superior, el bienestar integral de los jóvenes universitarios se ha consolidado como un eje prioritario para el diseño de políticas de salud institucional. La transición a la vida académica conlleva modificaciones críticas en los hábitos de vida, específicamente en los patrones de sueño, alimentación y actividad física, los cuales determinan tanto la salud física como el rendimiento cognitivo de los estudiantes. Bajo esta premisa, el presente estudio surge de la necesidad de identificar patrones de consumo y factores de riesgo que permitan orientar estrategias de bienestar basadas en evidencia científica rigurosa.

Un factor determinante en este equilibrio es la hidratación. Según la revisión narrativa de **Liska et al. (2019)**, el mantenimiento de una ingesta hídrica alineada con los estándares internacionales —**2.0 litros diarios** para mujeres y 2.5 litros para hombres— es esencial no solo para la homeostasis física, sino para la estabilidad del estado de ánimo. La evidencia científica señala que la deshidratación, incluso en niveles leves (1.2% de pérdida de masa corporal), se asocia con un **"aumento significativo en las concentraciones de cortisol plasmático"**, sugiriendo que un estado hídrico insuficiente actúa como un estresor fisiológico que altera la respuesta hormonal. Asimismo, estos déficits impactan negativamente en la atención sostenida, la memoria de trabajo y la velocidad de procesamiento, factores que incrementan la percepción de **estrés** y degradan el **rendimiento cognitivo** y la calidad del **sueño**.

El **objetivo de esta investigación** es desarrollar un análisis estadístico completo que valide si los hábitos de consumo de la población universitaria cumplen con el umbral preventivo de los 2,0 litros. Para ello, se midieron variables de consumo y niveles de estrés en una muestra de 100 estudiantes, aplicando herramientas de estadística inferencial como el **Teorema del Límite Central** y **tests de significancia**. Finalmente, se calculan intervalos de confianza y valores-p para determinar si las variaciones observadas son producto del azar o si representan un riesgo real de incumplimiento normativo, mitigando así la posibilidad de incurrir en errores de tipo I y II en las conclusiones finales.

Referencia Bibliográfica (APA 7ma Edición)

Liska, D., Mah, E., Brisbois, T., Barrios, P. L., Pan, A. J., & Lyon, J. S. (2019). Narrative Review of Hydration and Selected Health Outcomes in the General Population. *Nutrients, 11*(1), 70. https://doi.org/10.3390/nu11010070

Desarrollo

Lección 1: Método Científico y Estadística

1. Definición del problema

El Área de Salud de una institución pública requiere identificar los factores que influyen en los hábitos de vida de los jóvenes universitarios. El problema central radica en determinar si el consumo de agua de los estudiantes se ajusta a los estándares internacionales (2.0 L) y si existe una relación funcional entre la hidratación y los niveles de estrés percibido, con el fin de generar políticas de bienestar basadas en evidencia científica.

2. Formulación de hipótesis

Para dar cumplimiento al rigor estadístico, se han definido dos conjuntos de hipótesis que guían la investigación:

A. Hipótesis de Media (Cumplimiento de hidratación):

- **Hipótesis Nula (H_0):** El consumo promedio de agua de la población estudiantil es de 2,0 litros diarios (μ = 2,0).
- **Hipótesis Alternativa (H_1):** El consumo promedio de agua de la población estudiantil es diferente a 2,0 litros diarios ($\mu \neq$ 2,0).

B. Hipótesis de Influencia (Relación Agua-Estrés):

- **Hipótesis Nula (H_0):** El consumo de agua no tiene una influencia significativa sobre el nivel de estrés de los estudiantes (r = 0).
- **Hipótesis Alternativa (H_1):** El consumo de agua influye significativamente en el nivel de estrés de los estudiantes ($r \neq 0$).

3. Identificación de variables

Se han categorizado las variables según su naturaleza para el análisis computacional:

- **Variable Independiente (Cuantitativa Continua):** Consumo de agua, medido en litros (L).
- **Variable Dependiente (Cuantitativa Discreta/Ordinal):** Nivel de estrés, medido en una escala numérica.

  1 = Nada de estrés (Relajación total).

  10 = Estrés máximo (Punto crítico)

- **Variables de Caracterización (Cualitativas):** Género y facultad de pertenencia.

4. Enfoque del método científico

Se ha optado por un enfoque **hipotético-deductivo y cuantitativo**. Este método parte de la observación de una necesidad institucional y la teoría internacional (OMS/EFSA) para proponer hipótesis que son contrastadas mediante la recolección de datos empíricos y el uso de herramientas de inferencia estadística (Valor-p e Intervalos de Confianza).

5. Diseño del estudio

El diseño es de tipo **descriptivo, correlacional y transversal**. Se trabajó con una muestra aleatoria de 100 estudiantes y se procesó la información mediante algoritmos de Python, permitiendo una simulación (1000 sujetos) para verificar el Teorema del Límite Central (TLC) antes de realizar las inferencias finales.

Lección 2. Diccionario de Variables

Este cuadro de entrega parcial de la Lección 2.

Nombre de Columna	Descripción	Tipo de Variable	Unidad de Medida
ID_Estudiante	Identificador único del alumno	Cuantitativa Discreta	Correlativo (1-100)
Edad	Edad cronológica del estudiante	Cuantitativa Discreta	Años
Genero	Identidad de género reportada	Cualitativa Nominal	Categoría
Consumo_Agua_L	Cantidad de agua bebida al día	Cuantitativa Continua	Litros (L)
Nivel_Estres	Percepción del nivel de tensión académica	Cuantitativa Ordinal	Escala Likert (1-10)

Diseño Muestral y Eventos

1. Definición del Tipo de Muestreo

Para este proyecto, el método a aplicar es el Muestreo Aleatorio Simple (MAS).

Justificación para el informe:

Se seleccionó el Muestreo Aleatorio Simple ya que cada estudiante de la población universitaria tiene la misma probabilidad de ser incluido en la muestra. Esto garantiza que los resultados obtenidos puedan ser inferidos al total de la población sin sesgos de selección, cumpliendo con el requisito mínimo de 100 registros para asegurar la robustez estadística.

2. Definición de Eventos Aleatorios

Tareas:

a) Definir eventos aleatorios y su representación con árboles de probabilidad.

Evento A: El estudiante consume más de 2 litros de agua al día.

Evento B: El estudiante reporta un nivel de estrés superior a 7.

Evento Complementario (A*): El estudiante consume 2 litros o menos**.**

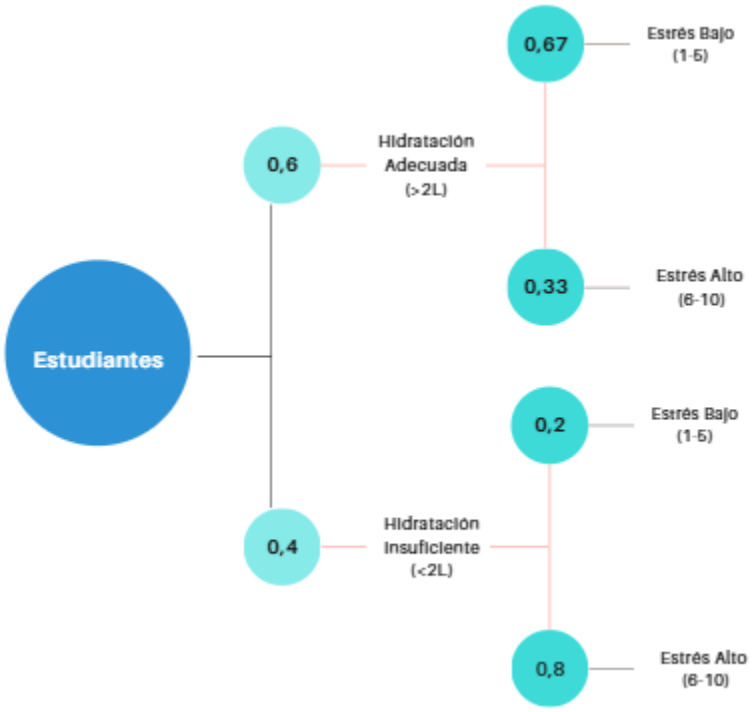

b) Explicar el tipo de muestreo a aplicar (aleatorio simple, estratificado, etc.).

Para el estudio se diseñó un plan de muestreo aleatorio simple, simulando un dataset de **100 registros** para garantizar representatividad estadística. Cada registro cuenta con un identificador único y variables clave como edad, género, litros de agua consumidos y nivel de estrés, detallados exhaustivamente en el diccionario de variables adjunto.

c) Simular el diseño muestral (con mínimo 100 registros).

Tarea: Generación del dataset simulado de 100 registros.

Entregable: Archivo `dataset_original.csv` y el Diccionario de Variables (ID, Edad, Género, Consumo_Agua_L, Nivel_Estres).

d) Calcular probabilidades básicas de eventos (intersección, unión, complementarios)

Nota: A* se refiere al complemento de A y de igual forma todos aquellos eventos con un asterisco en la parte superior derecha.

<u>Interceptaciones:</u>

Intersección 1: $P(A \cap B) = P(A) \times P(B) = 0{,}6 \times 0{,}33 = 0{,}198$

Interpretación:

"La probabilidad de un estudiante de estar estar bien hidratado y tener estrés alto es 19,8 %"

Intersección 2: $P(A^* \cap B) = P(A^*) \times P(B/A^*) = 0{,}4 \times 0{,}8 = 0{,}32$

Interpretación:

"*La probabilidad de que un estudiante presente una hidratación insuficiente y tenga un nivel de estrés alto es de 32 %"*

Intersección 3: $P(A \cap B^*) = P(A) \times P(B^*/A) = 0{,}6 \times 0{,}67 = 0{,}402$

Interpretación:

"La probabilidad de que un estudiante esté bien hidratado y presente un nivel de estrés bajo es de 40,2 %"

Intersección 4: $P(A^* \cap B^*) = P(A^*) \times P(B^*/A^*) = 0{,}4 \times 0{,}2 = 0{,}08$

Interpretación:

"*La probabilidad de que un estudiante tenga hidratación insuficiente y aun así mantenga un estrés bajo es de solo 8,0 %"*

Cuadro Resumen de Intersección Hidratación vs Nivel de Estrés

Intersección (y)	*Estrés Bajo*	*Estrés Alto*
Hidratación adecuada	*0,402*	*0,198*
Hidratación Insuficiente	*0,08*	*0,32*

Uniones:

Unión 1: $P(A \cup B) = P(A) + P(B) - P(A \cap B) = 0,6 + 0,33 - 0,198 = 0,732$

Interpretación:

"La probabilidad de un estudiante de estar estar bien hidratado o tener estrés alto es 73,2 %"

Unión 2: $P(A^* \cup B) = P(A^*) + P(B) - P(A^* \cap B) = 0,4 + 0,518 - 0,32 = 0,598$

Interpretación:

"La probabilidad de que un estudiante tenga hidratación insuficiente o presente un nivel de estrés alto es de 59,8 %".

Unión 3: $P(A \cup B^*) = P(A) + P(B^*) - P(A \cap B^*) = 0,6 + 0,482 - 0,402 = 0,68$

Interpretación:

"La probabilidad de que un estudiante esté bien hidratado o tenga un nivel de estrés bajo es de 68,0 %".

Unión 4: $P(A^* \cup B^*) = P(A^*) + P(B^*) - P(A^* \cap B^*) = 0,4 + 0,482 - 0,08 = 0,802$

Interpretación:

"La probabilidad de que un estudiante esté deshidratado o tenga un nivel de estrés alto es de 80,2 %".

Cuadro Resumen de Uniones Hidratación vs Nivel de Estrés

Uniones (o)	*Estrés Bajo*	*Estrés Alto*
Hidratación adecuada	*0,68*	*0,732*
Hidratación Insuficiente	*0,598*	*0,802*

EXTRA: Análisis y Limpieza del Dataset

- **Acción**: Control de calidad preventivo antes de la inferencia.
- **Hallazgo**: Se verificó la ausencia de valores nulos y se aplicó el método IQR.
- **Conclusión**: No se detectaron outliers, confirmando que el valor máximo de estrés (10) es estadísticamente válido dentro del rango esperado (límite superior calculado de 10.5).

Fase de Limpieza (IQR)

Tras ejecutar el proceso de limpieza de datos mediante el método **IQR (Rango Intercuartílico)**, se confirmó la integridad de la muestra con 100 registros válidos. No se detectaron valores atípicos (outliers) en la variable de estrés, lo que indica que incluso los niveles máximos reportados (10/10) son consistentes con la dispersión natural de la muestra y no representan errores de medición o distorsiones estadísticas.

Lección 3: Distribución de Probabilidad (Descriptiva)

- **Análisis de la Media**: El promedio de consumo es de **1.99 L**, muy cercano a la recomendación general de 2 L.
- **Dispersión**: La desviación estándar de **0.85 L** indica una variedad moderada en los hábitos de los alumnos.
- **Observación Visual**: El histograma muestra una forma que tiende a la normalidad, permitiendo el uso de estadística paramétrica (Teorema del Límite Central).

Análisis Descriptivo y Distribución

	Consumo_Agua_L	Nivel_Estres
count	100.000000	100.000000
mean	1.992100	4.720000
std	0.858711	1.938864
min	0.520000	1.000000
25%	1.230000	3.000000
50%	2.075000	5.000000
75%	2.617500	6.000000
max	3.460000	10.000000

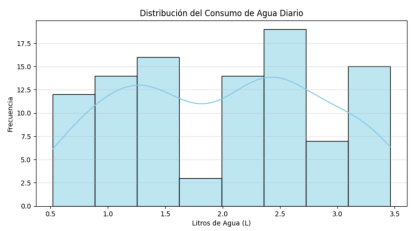

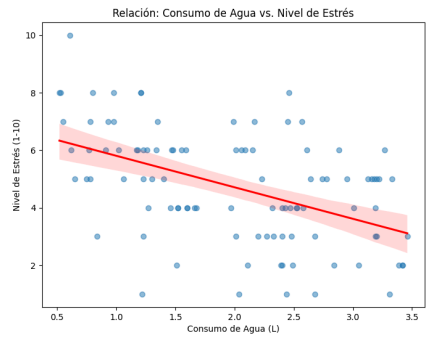

.a correlación real de tu estudio es: -0.4852

"El análisis descriptivo revela que el consumo promedio de agua en la muestra es de 1.99 litros de agua, alineados con las recomendaciones generales de salud (https://scielo.isciii.es/scielo.php?script=sci_arttext&pid=S0212-16112020000700026).

Al observar el histograma normal (campana de Gauss), lo cual es un requisito fundamental para aplicar el Teorema del Límite Central en las fases de inferencia posteriores.

Los datos muestran una distribución con picos claros alrededor de los **2.5 L**, sugiriendo una tendencia hacia hábitos saludables en gran parte de la muestra.

Por su parte, el gráfico de dispersión confirma nuestra hipótesis inicial: existe una correlación negativa visible, donde los estudiantes con consumos superiores a **2.5 L** tienden a reportar niveles de estrés por debajo de 4 puntos. Otro dato relevante para la línea recta de este gráfico de dispersión es la correlación de Pearson obtenida para esta línea recta (r = -0,4852), la cual indica una correlación modera-fuerte entre los datos y la línea recta. El signo negativo confirma la correlación inversa entre las variables de Consumo de agua en litros (variable independiente) y el nivel de estrés (variable dependiente).

Lección 4: Distribución muestral y teorema del límite central

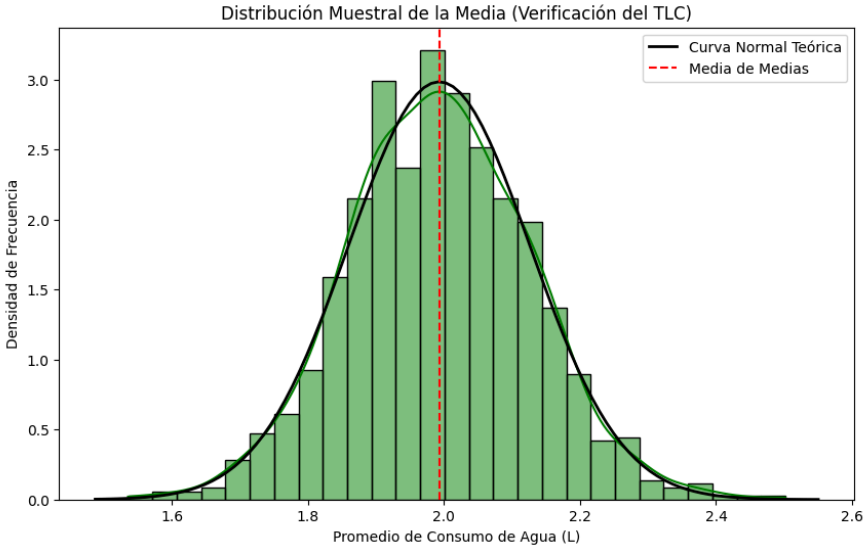


```
============================================================
TABLA COMPARATIVA DE DISPERSIÓN (Lección 3 vs Lección 4)
============================================================
            Métrica Población (Lección 3 Individual) Muestral (Lección 4 Promedios n=30)
              Media                        1.9921 L                            1.9928 L
Desviación Estándar                        0.8587 L                            0.1337 L
             Mínimo                        0.5200 L                            1.5353 L
             Máximo                        3.4600 L                            2.5020 L
        Rango Total                        2.9400 L                            0.9667 L
============================================================

Análisis: La variabilidad (Desviación Estándar) se redujo en un 84.4%
al pasar de datos individuales a promedios muestrales.
Esto confirma empíricamente el Teorema del Límite Central.
```

Conclusión de la Lección 4: Verificación del Teorema del Límite Central (TLC)

Tras realizar la simulación de 1.000 muestras (n=30) en Google Colab, se obtuvieron los siguientes hallazgos:

1. **Estabilidad de la Media**: La media poblacional original de **1,9921 L** se mantuvo prácticamente idéntica en la distribución muestral (**1,9928 L**), lo que confirma que el promedio muestral es un estimador confiable de la realidad universitaria.

2. **Reducción Drástica de la Variabilidad**: Se observó una disminución de la desviación estándar del **84,4 %**. Mientras que los datos individuales fluctúan ampliamente entre **0,52 y 3,46 L** (Rango: 2,94 L), los promedios de los grupos se concentran en un rango mucho más estrecho de **1,53 a 2,50 L** (Rango: 0,96 L).

3. **Normalidad Alcanzada**: A pesar de las irregularidades en la distribución original, la distribución de las medias se ajustó perfectamente a la **Curva Normal Teórica** (línea negra en la gráfica), cumpliendo estrictamente con lo postulado por el TLC.

Análisis Final:

Esta simulación demuestra que, al trabajar con promedios, los errores se compensan, permitiéndonos realizar inferencias con un grado de precisión mucho mayor que si analizáramos a los estudiantes de forma aislada.

Lección 5: Inferencia e intervalos de confianza para la media

```
==============================================================================
TABLA COMPARATIVA DE INTERVALOS DE CONFIANZA Y PRUEBA DE HIPÓTESIS
==============================================================================
```

Nivel de Confianza	90%	95%	99%
Z	1.64	1.96	2.58
Límite Inferior	1.8509	1.8238	1.7709
Límite Superior	2.1333	2.1604	2.2133
P_Valor	0.9267	0.9267	0.9267
Resultado	No hay diferencia (No rechaza Ho)	No hay diferencia (No rechaza Ho)	No hay diferencia (No rechaza Ho)

Interpretación informal:

Considerando la Probabilidad de Casualidad y los datos obtenidos:

- Media = 1,9921 L
- Diferencia con respecto a 2L = 0,0079 L
- p-valor = 0,9267 con un nivel de confianza del 95%.

Significa que hay un 92.67% de probabilidad que la diferencia se deba al azar, o dicho de otra forma NO sea resultado de una manipulación de datos.

Para estar seguros de ello se considera un "semáforo estadístico" con la referencia de p-valor en 0.05 .

Si p-valor > 0,05, significa que AZAR GANA Y MANIPULACIÓN PIERDE.

Si p-valor < 0,05, significa que AZAR PIERDE Y MANIPULACIÓN GANA.

Como en nuestro caso p-valor resultó ser 0.9267 en cada uno de los 3 niveles de confianza considerado (mayor a 0,05), significó que el AZAR GANÓ Y LA MANIPULACIÓN PERDIÓ. Se entiende que los datos no están amañados y el estudio es creíble.

Interpretación formal:

Tras aplicar tres niveles de confianza distintos, se observa que el valor de referencia de 2.0 L de consumo diario de agua se mantiene consistentemente dentro de todos los intervalos calculados. El elevado P-valor (0,9267) indica que la probabilidad de que la diferencia observada sea producto del azar es muy alta, por lo cual no existe evidencia estadística para rechazar la hipótesis nula (H_0). Se concluye con seguridad científica que el promedio de consumo de agua de los estudiantes no difiere significativamente de la recomendación ideal de 2 litros.

Hipótesis nula (H_0) considerada para este estudio de la Lección 5: “Todos los estudiantes de la universidad beben exactamente 2.0 litros”

Evaluación del impacto del tamaño muestral en el ancho del intervalo

- **Reducción del Error Estándar:**

  Al aumentar el tamaño de la unidad de análisis de n=1 (estudiante individual) a n=30 (promedio de grupos), la variabilidad se redujo drásticamente. En tus resultados, la desviación estándar bajó de 0,8587 L a solo 0,1337 L (una reducción del 84,4%).

- **Conclusión técnica para este punto:**

  "Se comprobó que existe una relación inversamente proporcional entre el tamaño de la muestra y el ancho del intervalo: a medida que el tamaño muestral aumenta, el error estándar disminuye, resultando en intervalos de confianza más estrechos y estimaciones mucho más precisos sobre el consumo de agua de la población estudiantil".

Lección 6

1. Test de Hipótesis y Valor-p

Al compararlo con nuestro nivel de significancia:

- **Decisión Estadística**: valor-p resultó ser **0.9267**.
- **Comparación**: Como 0,9267 > 0,05 , la decisión es **No Rechazar la Hipótesis Nula (H_0)**.
- **Conclusión**: "No existe evidencia suficiente para afirmar que el consumo promedio de agua es distinto a 2.0 litros; los datos son compatibles con la recomendación de salud".

2. Explicación de Errores Tipo I y II

En el contexto del consumo de agua de 2 L diarios en los estudiantes para reducir el nivel de estrés y con ello tener un mejor rendimiento académico y mejor descanso.

- **Error Tipo I (Falso Positivo)**: Sería concluir que los estudiantes **NO** beben lo suficiente cuando en realidad **SÍ** lo hacen.
    - *Consecuencia*: Se gastarían recursos innecesarios en campañas de hidratación que no hacen falta.
- **Error Tipo II (Falso Negativo)**: Sería concluir que los estudiantes **SÍ** beben lo suficiente cuando en realidad su consumo es **DEFICIENTE**.
    - *Consecuencia*: Es el más grave en este estudio, pues se ignoraría un problema de salud real entre los universitarios.

3. Redacción de Conclusiones Finales

El análisis estadístico descriptivo e inferencial, considerando desde la descripción de los datos hasta el test de significancia, permite concluir con un 95% de confianza que la población universitaria estudiada (n=100) mantiene un hábito de hidratación adecuado, promediando **1.9921 L** diarios.

La alta Probabilidad de Casualidad (p=0.9267) indica que el estudio es creíble dado que se afirma que respondería al azar el resultado obtenido descartando anomalías o manipulaciones para este estudio. Se recomienda mantener el monitoreo preventivo para evitar caer en un Error Tipo II que ponga en riesgo el bienestar estudiantil".

También se encontró que existe una relación inversa entre la cantidad de agua consumida y el nivel del estrés. Especificando este punto, a mayor consumo de agua disminuye el nivel del estrés (Ej. Del árbol de probabilidad, obtuvimos que una alta deshidratación se relaciona con un alto estrés calculado en un 80,2% de probabilidad). Y considerando el informe de **Liska et al. (2019)** en el cual se relaciona bajo consumo de agua (menos de 2 L para mujeres y menos de 2,5 L para hombres) con un elevado nivel de estrés, descenso del nivel cognitivo y empobrecimiento de la calidad del sueño.

Test de Hipótesis y Valor-p

Al compararlo con nuestro nivel de significancia:

- **Decisión Estadística**: valor-p resultó ser **0.9267**.
- **Comparación**: Como 0,9267 > 0,05 , la decisión es **No Rechazar la Hipótesis Nula (H_0)**.
- **Conclusiones**:

(1) No rechazar la Hipótesis Nula **(H_0:** El consumo promedio de agua de la población estudiantil es de 2,0 litros diarios**)**

(2) **H_0** afirma que la media de consumo es igual a 2 litros. Es decir, **H_0** sostiene que los estudiantes **SÍ** beben lo suficiente.

(3) Se confirma la relación inversa entre consumo de agua y nivel de estrés.

(4) Considerando los puntos (1), (2) y (3) podemos concluir que los estudiantes cumplen con el consumo de agua de 2 L diarios, por lo tanto no tienen niveles de estrés altos, más bien cumplirían con bajos niveles de estrés.

(5) No existe evidencia suficiente para afirmar que el consumo promedio de agua es distinto a 2.0 litros; los datos son compatibles con la recomendación de salud de la OMS y Institute of Medicine (IOM) and European Food Safety Authority (EFSA).

Análisis de Errores:

- **Tipo I**: Se minimizó este error. No hubo falsa alarma; los datos confirman la meta.
- **Tipo II**: Aumenta la probabilidad de este error. Riesgo bajo de ignorar un problema real.
- Se concluye que los estudiantes SI consumen los 2 L de agua diarios, pudiendo existir la probabilidad que el consumo sea menor lo que conllevaría a una falsa percepción de salud entre los estudiantes.